RelateAnything 复现汇报：精华材料与PPT提示词

用途：将本文直接交给PPT生成LLM，生成一份约8页主汇报加1页备份的中文学术汇报。建议汇报时长8–10分钟。所有结果来自本地实验报告，不能把诊断性探针写成论文主张。

可直接粘贴的PPT生成提示词

```
请根据下方“汇报材料”制作一份中文学术汇报PPT，主题为《RelateAnything：官方权重复现与关系预测能力诊断》。听众是安排我做这场复现的老师，汇报时长8–10分钟，主体8页，另加1页“局限与后续工作”备份页。

叙事主线：我们先用官方发布权重在完整公开PSG测试集上复现主表对应行，再用固定变量实验检查模型依赖什么输入、对框误差和表达变化有多敏感，最后用全量失败分解解释结果。重点回答“复现是否可信、模型表现依赖什么、错误发生在哪一环”。本次PPT不安排T01单样本追踪，不使用其流程图、词表方向对照图或单图案例。

制作要求：
1. 先讲研究问题和实验设计，再展示结果，最后给出克制的结论。每页只表达一个中心结论，标题尽量写成结论句。
2. 用图表优先：主表对照、扰动曲线、图像干预对比、失败阶段堆叠/条形图。优先使用文末“配图素材”中直接展示的图片，页序表以图号对应。若生成系统只能读取Markdown文本而不能访问本地图片，需同时提供这些图片附件；不要虚构图片或结果。
3. 把百分数、百分点、样本数和实验条件写准确。论文数值和本地复现值并列展示；不要把E02的seed标准差称为置信区间。E03需强调配对区间跨零。E01旧58.33%只能称短语探针；E01b是分数可见后的助手事后语义分层，不是独立盲审。
4. 严格区分“观察到的结果”和“可能解释”。不要宣称注意力图证明模型理解了关系；不要把均值图结果称为纯几何baseline；不要称E04为视觉理解占比；不要称发布权重测试为从头训练复现。
5. 必须说明本地公开数据转换为2179张、13609条关系，论文报告13623条，尚差14条未归因。因此结论是当前公开转换版本下的近似复现，不是逐数据完全一致。
6. 明确没有进行训练、RA-4M逐轮VLM数据生成审计、真实检测器SGDet及第二人独立语义盲审。不要把这些写成“因为资源不足所以失败”的故事，也不要暗示已经完成；可在最后的局限页简洁列出。
7. 版式采用干净、克制的研究汇报风格；图表标清数据集、样本量、指标和单位。减少长段文字，关键数字大字突出。末页用一句话收束：“官方权重的PSG复现可信；模型对框和图像输入敏感；谓词选择与全图排序是漏召回的重要环节。”

下面是可用于制作幻灯片的全部事实、实验结论和图片索引。不得补造其他数字。
```

汇报材料

一句话结论

在RTX 5070 Ti上使用官方发布权重，RelateAnything在公开PSG测试集复现了接近论文的R@50/mR@50/F1@50；独立复算和固定批次复跑支持执行可信。进一步实验表明，定位框扰动和图像证据变化会影响预测，严格谓词匹配也会把“关系看起来合理但谓词不同”的结果判为漏召回。实验没有训练模型，也没有重生成RA-4M。

背景与问题

RelateAnything是开放词汇场景图关系预测模型：给定图像、物体区域和待检索关系词表，输出有向的(subject, relation, object)三元组及分数；推理时可替换候选词表，不必为新短语重新训练。本次复现关注三个问题：

1. 官方权重能否在公开PSG完整测试集上复现主表指标?
2. 预测对区域定位、视觉图像证据及关系表达变化有多敏感?
3. 真实样本中的漏召回发生在候选采样、谓词选择还是全图排序阶段?

实验范围与可信度

- 硬件：NVIDIA RTX 5070 Ti，约16GB显存；推理使用官方ViT-S+发布权重、448输入、BF16。
- 数据：公开PSG测试JSON共2186张，经官方转换保留2179张、13609条关系；实际计分2177张。论文报告13623条关系，差14条未能归因，因此定位为**当前公开转换版本下的近似复现**。
- 7张图因原始标注只有1个框且没有关系而被转换器排除；另2张保留图片原本就没有关系，不计入召回分母。转换后的本地pack由官方转换器重建，四个数组与文件名逐项一致。
- B01完整测试的R/mR/F1由官方评测器与独立实现复算一致；32个完整条件独立重算指标最大差约1.1×10^-16；固定首批GPU复跑top100三元组一致。
- 本次**未进行训练/微调、RA-4M三轮VLM生成、真实检测器SGDet或独立第二人盲审**。只报告已经执行的推理和控制实验。

核心结果

指标	论文报告	本地完整PSG测试	差值
R@50	40.10%	40.11%	+0.0066个百分点
mR@50	30.60%	30.76%	+0.1615个百分点
F1@50	34.70%	34.82%	+0.1179个百分点

本地同一测试集的完整K值：R@20/50/100 = 34.67%/40.11%/41.90%；mR@20/50/100 = 28.36%/30.76%/31.48%；F1@20/50/100 = 31.20%/34.82%/35.95%。此处F1是R与mR的调和平均，遵循项目评测定义。

实验设计与发现

实验	设计与规模	结果及可支持的结论
B01 完整基准	官方权重；2179张推理、2177张计分；GT框；官方图约束评分协议	三项@50均接近论文结果，且独立复算一致。支持官方权重在当前公开PSG转换版本上的推理复现。
V01 注意力诊断	12个固定关系对；比较主体/客体区域注意力与框面积占比	主体/客体query平均框内注意力质量0.8187，框内patch面积占比0.1900。表明注意力集中于框内，不足以单独证明模型理解关系或注意力对结果有因果贡献。
E01/E01b 表达变化	E01：6类关系、24个固定物体对，预设改写与控制；E01b：对原样本事后语义分层	E01原58.33%是混合短语探针，不能称严格同义鲁棒性。E01b语境等义且控制可判假的子集11/12改写胜出，95%图像聚类bootstrap区间70%–100%；但仅9张图，且是分数可见后的助手标注，不是独立盲审。
E02 框扰动	300张图；平移和缩放两类误差；4档强度，各3个seed；25个条件	原图R@50=39.36%。强度0.20时，平移R@50均值30.60%，缩放35.75%。平移条件的空间/语义候选覆盖仍为99.72%/99.46%，退化主要出现在已覆盖候选的谓词/排序阶段，而非候选对大量消失。
E03 pair项	完整测试输出固定，只把排序中的pair_weight从1改为0	R@50由40.11%到40.19%，差+0.0859个百分点；配对95%区间[-0.0203,+0.1945]个百分点，跨零。没有证据支持该项在此测试上有明确收益或损害。

实验	设计与规模	结果及可支持的结论
E04 图像干预	固定300张图及框；比较原图、模糊、灰度、空间均值图、图像错配	R@50：39.36%、20.31%、38.66%、4.44%、11.13%。模糊/均值/错配下降明显，灰度接近原图；支持输出依赖图像输入，但均值和错配是分布外干预，不等于纯几何对照，也不能定量视觉理解占比。

建议的8页结构

页	结论型标题	页面要点	推荐配图
1	官方权重在PSG上复现了论文主表结果	研究主题、开放词汇关系预测任务、三个研究问题	简洁任务示意与一句话结果，无需复杂流程图
2	复现协议与数据版本经过逐项核验	RTX 5070 Ti；官方权重/BF16；2186→2179→2177；14条关系差异边界	可用简化数据流程图，数字见本材料
3	主表三项指标均接近论文报告	展示R@50、mR@50、F1@50双方并列及百分点差	图1：主表对照
4	表达变化的结论必须先控制语义是否等价	E01短语探针与E01b事后语义分层；不要把58.33%到91.67%表述为模型性能提升	图2：E01样本总览；可根据本材料重绘分层结果表
5	框误差会降低召回，强平移影响更明显	平移/缩放曲线；0.20强度结果；解释候选覆盖保持而候选内预测退化	图3、图4：平移与缩放曲线
6	预测会随图像证据改变，但干预不能等同机制证明	原图、模糊、灰度、均值图、错配R@50并列；强调分布外边界	图5：图像干预
7	失败不仅是“没找到物体对”，谓词与排序也会出错	完整测试集5287命中、7453谓词错误、445排名低于50、41未选中；分开解释三种失败机制	图6：全量失败阶段
8	复现可信，微小差值和表达鲁棒性仍需谨慎解释	总结可信证据；E03区间跨零；E01语义边界；14条数据差异与工作范围	图7：配对不确定性；结论区保持简洁

备份页建议：E01语义分层详细结果。展示E01 58.33%为何不等于严格同义鲁棒性，以及E01b 11/12、9图、区间70%–100%和事后标注边界。也可把完整K=20/50/100指标放在附录。

演讲时值得讲清的全量失败分解

判定阶段	去重GT数量	含义
命中top50	5287	最佳谓词正确，且在全图前50条中
最佳谓词错误	7453	物体对已被选中，但保留的最佳谓词未匹配GT
全图排名低于50	445	物体对已选中且最佳谓词正确，但全图排序未进入前50
物体对未选中	41	GT有向物体对未进入候选集合

总计13226条去重GT。要点是：候选覆盖高并不意味着召回高；仍需预测正确的谓词，并在全图排序中进入top50。这里展示的是关系计数分解，不能直接用5287/13226替代主表按图聚合的R@50。

推荐的最终汇报结论

> 我们完成了官方发布权重在公开PSG测试集上的近似复现，主表指标与论文接近，推理输出通过独立复算和固定批复跑。控制实验显示模型依赖图像输入，并对框定位误差敏感；失败可以分解为候选、谓词和排序问题。词义鲁棒性结论仍受小样本事后标注限制。由于公开转换版本与论文关系数仍差14条，本工作不宣称数据逐项完全一致，也不宣称完成训练或RA-4M生成复现。

配图素材（直接显示图片）

以下使用Markdown图片语法，支持图片预览的阅读器可直接显示。图片仍由相对路径引用；将材料交给外部LLM时，应连同图片上传，或使用支持携带图片的文档导出方式。

图1：官方报告与本地完整测试集对照

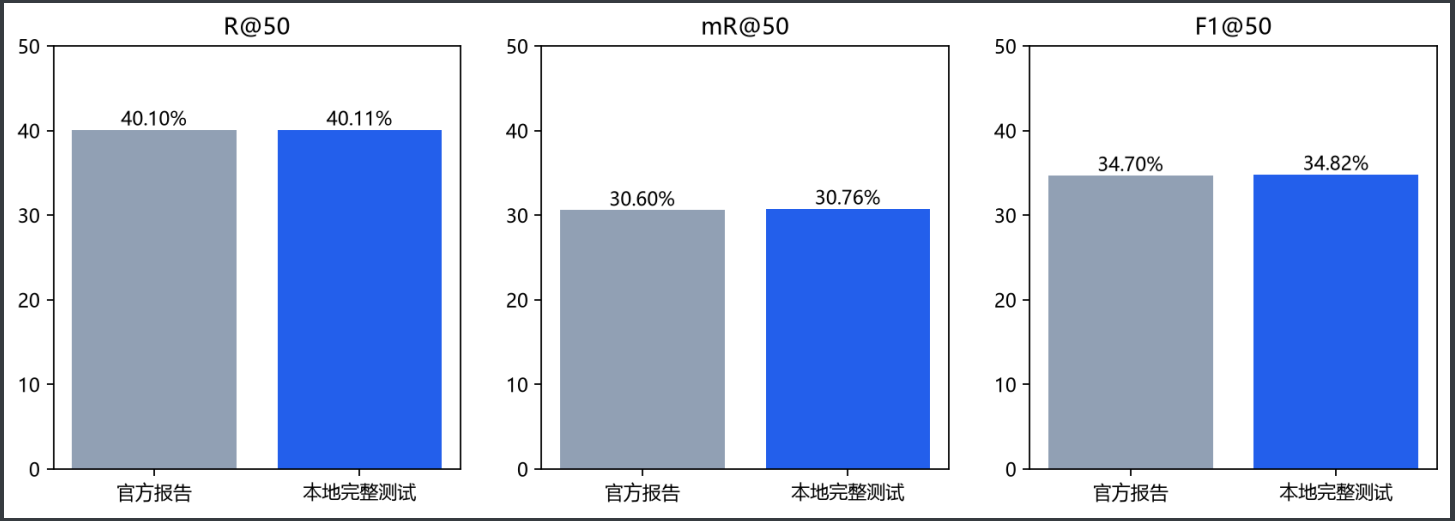


图2：Eo1固定关系对样本总览

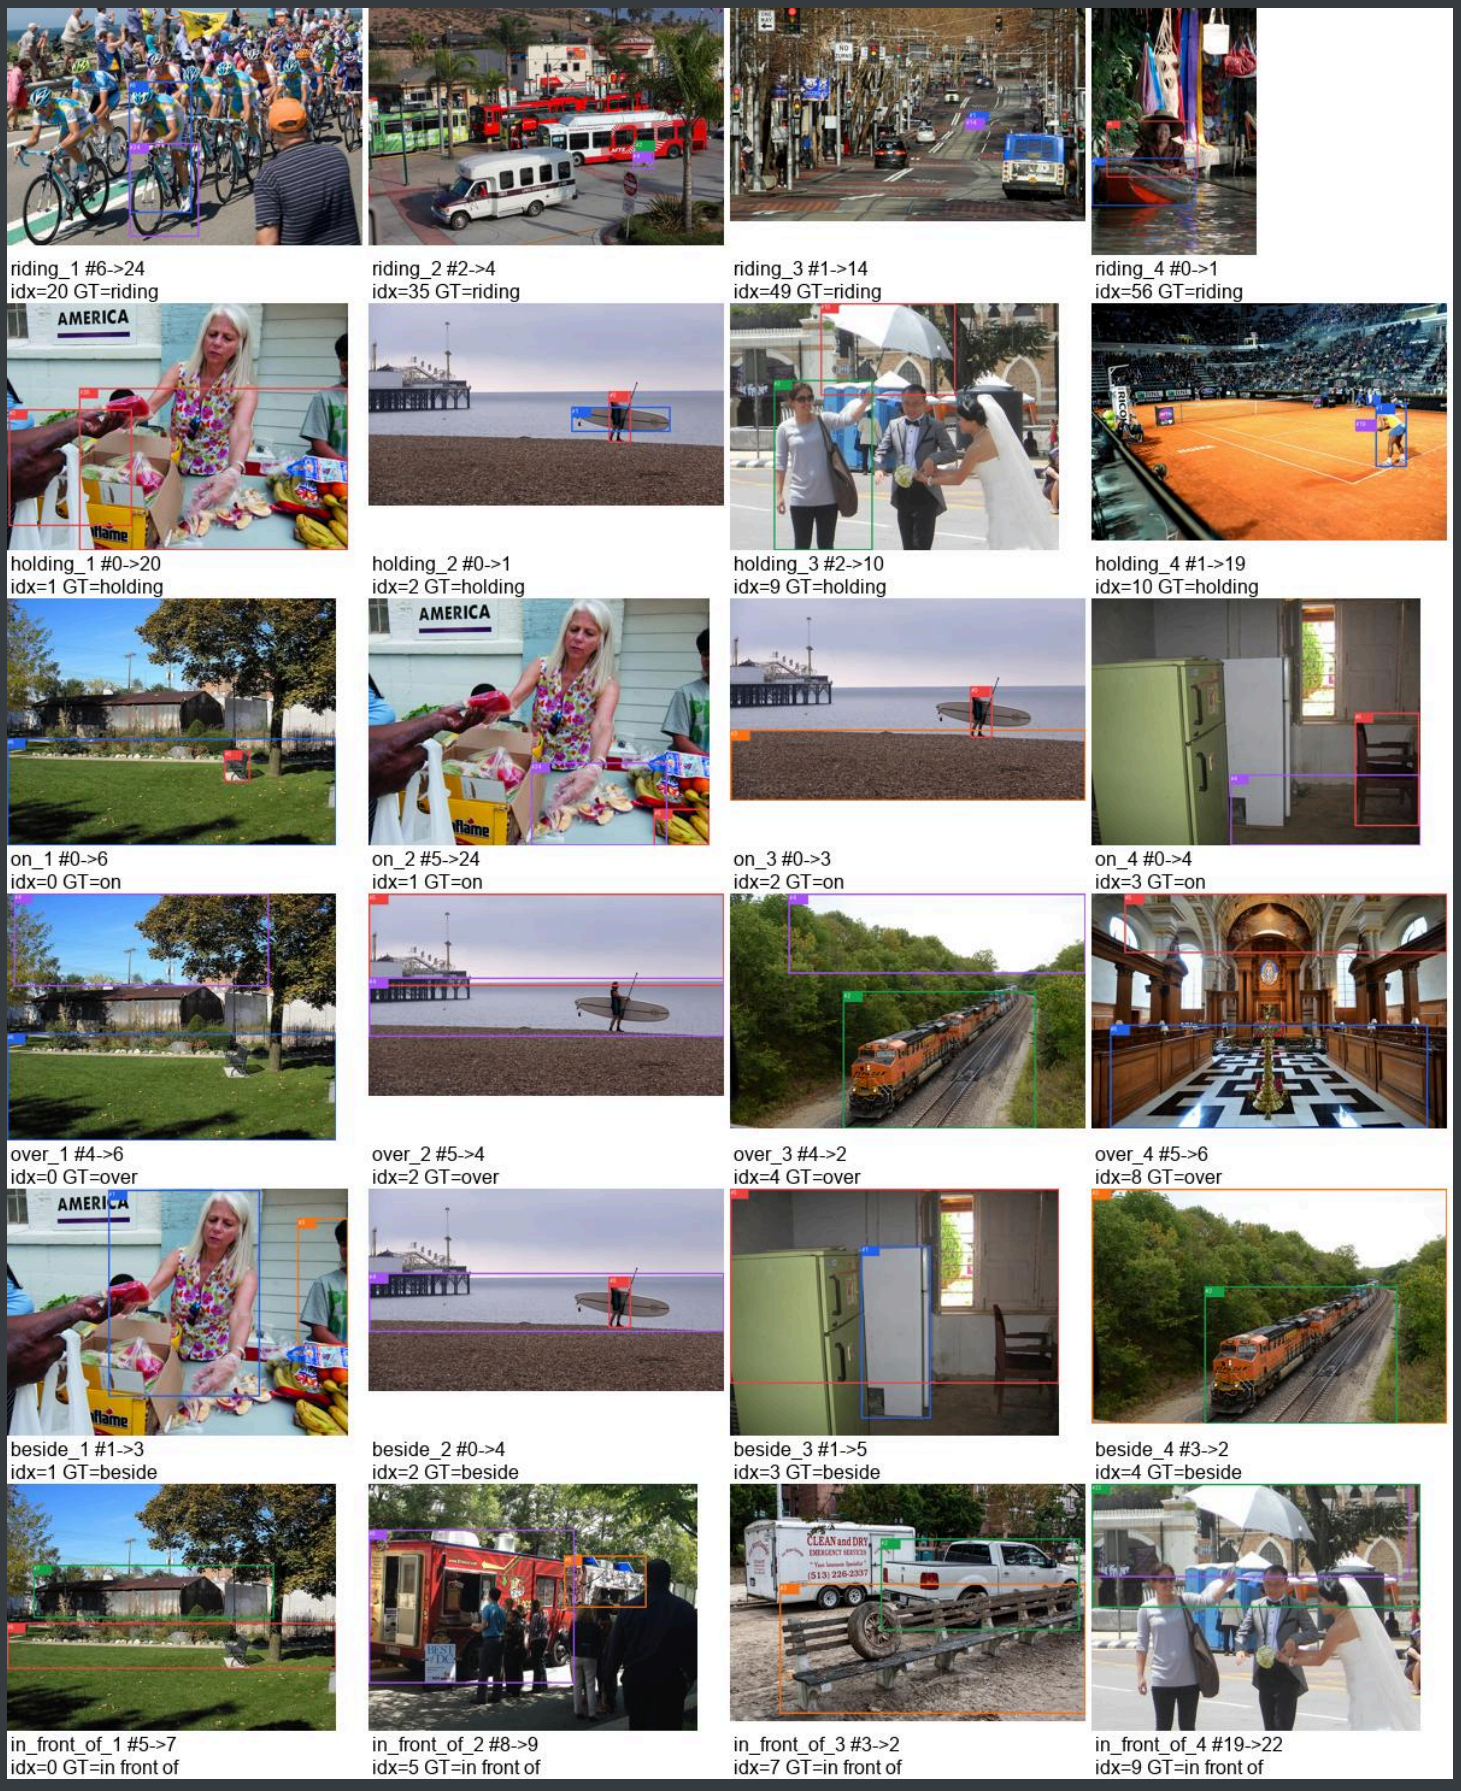


图3：定位框平移扰动

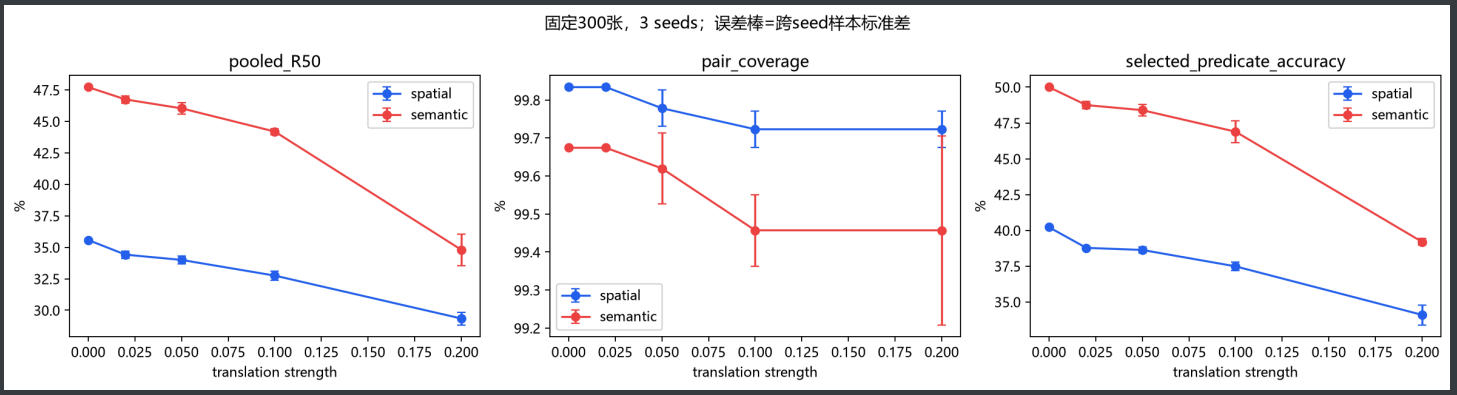


图4：定位框尺寸扰动

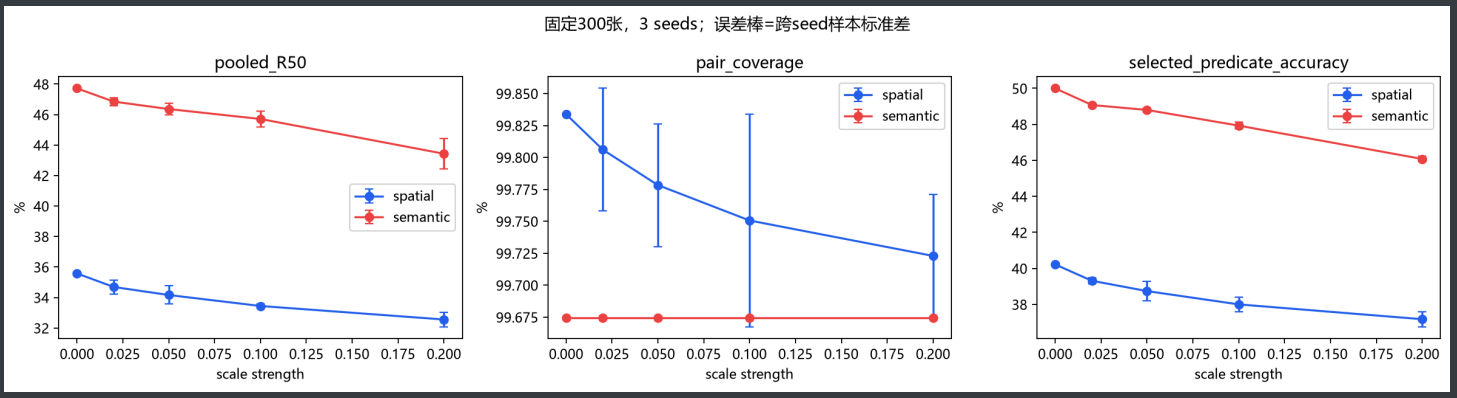


图5：图像证据干预

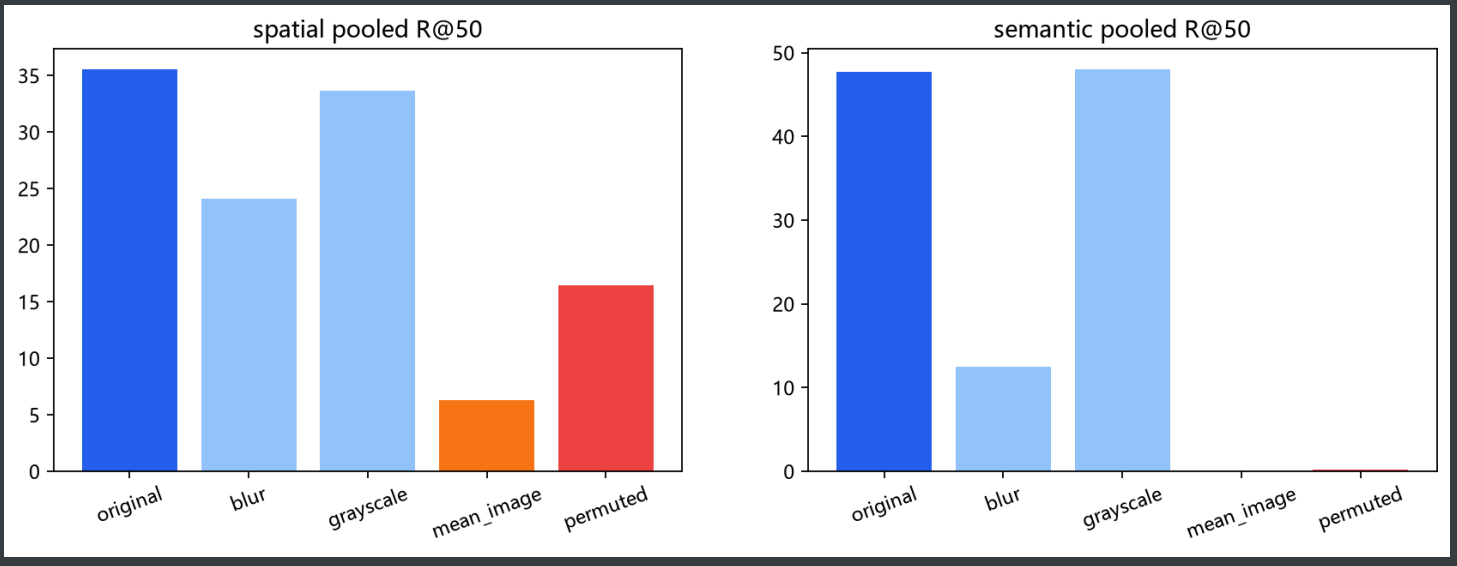


图6：完整测试集失败阶段分解

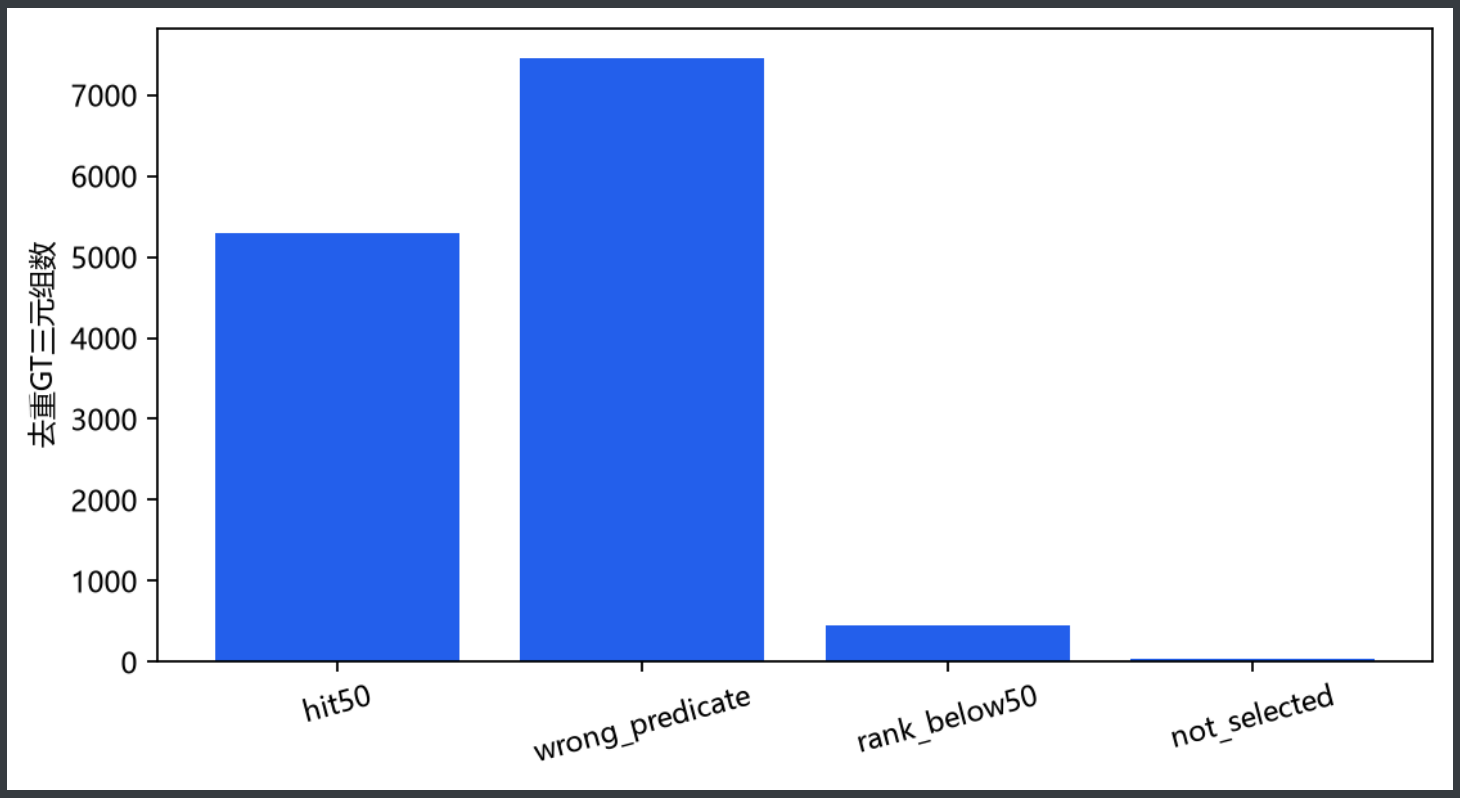
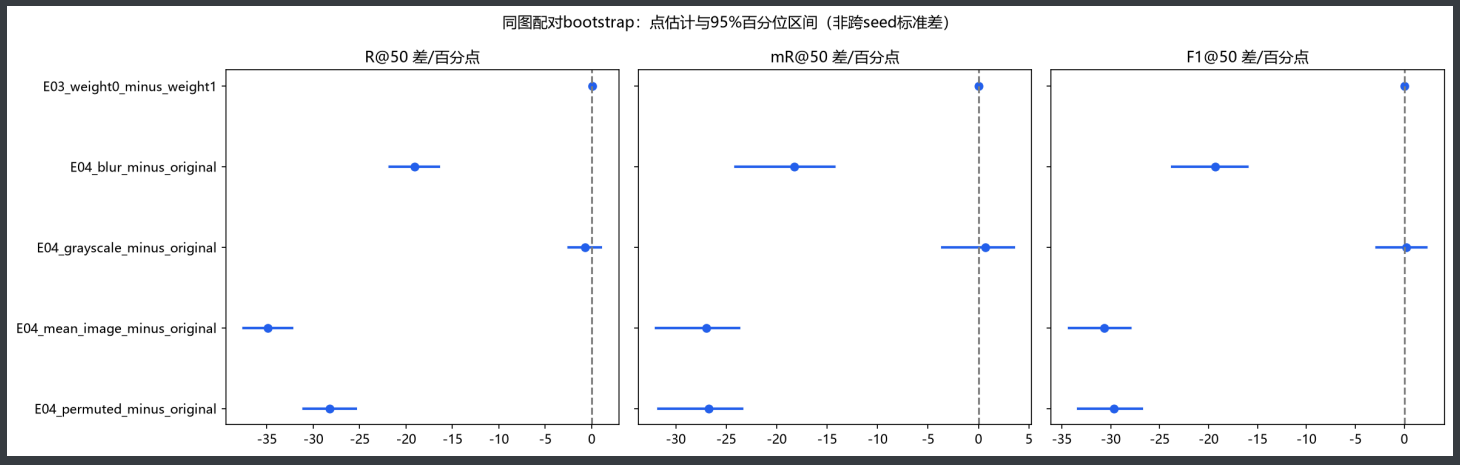


图7：图像级配对bootstrap不确定性



详细方法、逐例结果、来源与复跑脚本见完整实验报告及审查修订与新增实验。